

Système de reconnaissance d'entité appliqué au WOLOF

La reconnaissance d'entités nommées ou **named entity recognition** (NER) est le processus d'identification de groupes spécifiques de mots qui partagent des caractéristiques sémantiques communes. Il s'agit d'une sous-tâche de l'activité d'extraction d'information à partir de documents consistant à rechercher des objets textuels (c'est-à-dire les entités nommées) catégorisables dans des classes telles que:

- des noms de personnes,
- des noms d'organisations ou d'entreprises,
- des noms de lieux,
- des quantités, distances, valeurs, dates, etc.

Exemple :

« À l'instar de **Roberto Martinez** **PER**, il nous reste un goût amer dans la bouche. « C'est vraiment dommage qu'on n'ait pas un stade national pour pouvoir célébrer cette incroyable génération de joueurs pendant l'Euro... ». Et le journal de poursuivre : « C'est même particulièrement navrant. Tête de série, la **Belgique** **LOC** aurait pu revendiquer au minimum deux matchs à domicile dans un « **Eurostadium** **LOC** » flamboyant neuf, sis sur le parking C du **Heysel** **LOC**. Un projet qui a coûté plus de **25 millions d'euros** **MONEY** pour, in fine, échouer lamentablement, entre querelles à différents niveaux de pouvoir et à relents communautaires. « Retirée par l'UEFA des villes hôtes en **décembre 2017** **DATE**, **Bruxelles** **LOC** n'aura donc pas de stade national... et n'en aura sans doute jamais. Aucun gouvernement – à condition déjà d'en avoir un – ne semble prêt à s'accorder à ce niveau. (...) Bref, une véritable « histoire belge », notre royaume étant, à ce stade, la risée de l'Euro(pe). À charge désormais des **Diablos** **LOC** de nous éviter de l'être sur le terrain. Y compris à l'autre bout du continent », conclut le journal.

L'objectif de ce projet sera donc de **concevoir un système de reconnaissance d'entités nommées** à partir de l'ensemble de formation (train) et l'ensemble de validation (dev) fournis. **Vous utiliserez l'ensemble de formation pour l'entraînement du modèle afin de prédire les étiquettes pour chaque mot de l'ensemble d'évaluation (test) afin d'obtenir la reconnaissance d'entité.**

Dans votre ensemble de données il y a plusieurs étiquettes (B-PER, I-PER, B-LOC, I-LOC, B-DATE, I-DATE, B-ORG, I-ORG, 0). Ces étiquettes constitueront vos labels dans le modèle de classification supervisée que vous allez mettre en place.

PS : Vous n'êtes pas obligées d'avoir 9 labels différents. Une idée serait peut-être de grouper les labels et d'en former un couple, par exemple DATE = B-DATE et DATE = I-DATE. Ce qui réduira vos étiquettes

Métriques pour l’Evaluation du modèle

Les métriques standard utilisées pour la reconnaissance d'entités nommées (NER) sont généralement le recall, la precision et le F1 score, **évalués au niveau de l'entité et non au niveau du jeton**. Pour ce projet on utilisera spécifiquement le F1-Score qui est connu pour être un metric de référence lorsqu'on est en face de données déséquilibrées par exemple .

$$F1\ Score = 2 \times \frac{recall \times precision}{recall + precision}$$

Bonus

Une fois le modèle testé et validé, vous pouvez vous amuser à mettre en place sur Streamlit une mini-application qui donnera à l'utilisateur le choix d'écrire du texte en entrée et en sortie, votre modèle lui produira le même texte avec les entités nommées. Si vous n'êtes pas inspiré pour écrire du texte en wolof, vous pouvez vous servir du site : <https://www.presidence.sn/wo/> qui est le site de la Présidence avec une partie en Wolof où vous pouvez scraper des corpus de textes et les tester avec votre modèle sur Streamlit.

Interêt du projet.

En plus d'une portée éducative, ce projet peut avoir une portée commerciale. En effet, vous pouvez le commercialiser en proposant à des entreprises du Sénégal ou de la sous-région un système de reconnaissance d'entité. En effet, vous pouvez reajuster votre modèle avec les autres langues fournies par MasakhaNER qui est un ensemble de données NER pour 10 langues africaines comme :

- **amharique** (Langue nationale de Ethiopie)
- **haoussa** (Nigéria) ,
- **igbo**(Nigéria)
- **kinyarwanda** (Langue nationale du Rwanda)
- **luganda**(Ouaganda) , luo (Kenya)
- **pidgin nigérian**
- **swahili**(Tanzanie, Kenya, Ouganda, Rwanda, Burundi, République démocratique du Congo)

- **wolof**

- et **yorùbá**(Nigéria))

Vous pouvez ainsi créer des systèmes de reconnaissance d'entités pour ces 10 langues.

Données :

Vous pouvez retrouver les données wolof sur le site MashakhaNER :

<https://github.com/masakhane-io/masakhane-ner/tree/main/data/wol>

Note pour le modèle:

Vous pouvez vous inspirer de modèles déjà existants dans hugging face ou d'autres plateformes afin de faire du Fine-tuning et de l'adopter par rapport à votre tâche.

Avant d'utiliser un API assurez-vous que vous comprenez bien le modèle ou l'architecture derrière car vous serez notés sur la compréhension du modèle.

Pour les autres étudiants qui seront tentés de mettre en place leur propre architecture pour le NER, on ne s'attend pas forcément à avoir les meilleurs résultats mais l'intérêt est que vos résultats soient acceptables et surtout que vous soyez sûr que vous comprenez l'architecture que vous mettez en place .

Constitution des groupes :

Vu la portée et l'importance de ce projet, Vous y travaillerez en trinôme (sauf pour un groupe qui sera en quadrinôme) et voici les groupes constitués comme suit :

Groupe 1 : Guindogba - Meildnaxaviera - Ousmane

Groupe 2 : Makhtar - Djelia - Anoir

Groupe 3 : Ndioufa - POMANE - Jordy

Groupe 4 : Rokhaya - Babou - Adama - Moustapha

Chaque groupe aura **45 min** dans lequel il présentera :

- le modèle (architecture utilisé)
- Les points forts et faibles du modèle par rapport à d'autres modèles testés
- Les résultats du modèles
- L'application (Streamlit s'il est fait)
- Et enfin nous parler de ce qui a été difficile dans le mini-projet, ce qu'il a appris de nouveau ainsi que l'intérêt et la portée du projet pour le futur.